



Além da arquitetura: efeito dos particionamentos em NER na comparação entre BERT-like, LLMs e modelos estatísticos

Vítor Bernardo Silveira Pereira¹

Universidade Federal do Rio Grande do Sul (UFRGS)

Dennis Giovani Balreira²

Universidade Federal do Rio Grande do Sul (UFRGS)

Resumo: Investigamos, em *Named Entity Recognition* (NER), como duas decisões do sistema: a arquitetura do modelo e a forma de dividir os dados em treino, validação e teste, afetam as métricas de desempenho. NER consiste em identificar e classificar, no próprio texto, menções a entidades (por exemplo, pessoas, lugares, organizações). Comparamos três famílias: (i) modelos estatísticos clássicos, como *Conditional Random Fields* (CRF) e redes LSTM; (ii) modelos *BERT-like*, *encoders* pré-treinados por mascaramento de palavras e depois ajustados à tarefa; e (iii) *Large Language Models* (LLMs), modelos generativos de grande porte treinados para gerar o próximo *token*. LLMs lideram muitas tarefas de geração. No entanto, em NER seu resultado depende fortemente de como formulamos a instrução (*prompt*), do controle de aleatoriedade (temperatura) e da formatação da entrada, o que tende a aumentar a variabilidade das métricas.

Para isolar o efeito do particionamento, avaliamos quatro estratégias de *split*: (a) padrão/estratificado; (b) aleatório com reamostragens; (c) heurístico, controlando, por exemplo, comprimento de sentença e raridade lexical; e (d) adversarial, que amplia a distância entre treino e teste a partir de representações vetoriais (*embeddings*). Mantivemos o conjunto de validação apenas para seleção de *checkpoints* e reservamos o conjunto de teste para confirmação final, evitando contaminação do teste por decisões de ajuste. A comparação entre modelos e *splits* foi feita com o teste de McNemar, apropriado para decisões pareadas. As métricas analisadas foram F1-Score (com ênfase em F1-Macro) e acurácia.

Os resultados mostram que o *split* domina a arquitetura: mudar a estratégia de particionamento provoca variações em F1 maiores do que trocar de modelo. Os modelos *BERT-like* alcançam F1-Macro acima de 80% com variância baixa. Em contraste, os LLMs exibem amplitude típica de 5% a 40% em F1-Macro, dependendo do domínio e do *split*, ficando, em média, abaixo dos *BERT-like*. CRF/LSTM degradam mais sob *splits* heurísticos/adversariais, sugerindo maior sensibilidade a mudanças de distribuição.

Concluimos que *BERT-like* permanecem estado da arte em NER por duas razões complementares: alinhamento objetivo-tarefa, com representações bidirecionais adequadas à decisão discriminativa em nível de *token* e a degradação sob deslocamentos moderados de

domínio é menor que a observada em LLMs e em modelos clássicos. A contribuição do presente trabalho está em quantificar, de forma comparativa e estatisticamente controlada, a interação entre arquitetura e particionamento especificamente em NER, e em propor um protocolo de avaliação centrado em *splits*, com múltiplas estratégias e teste de significância, que reduz superestimções, evita inversões artificiais de ranking e fornece estimativas mais confiáveis para implantação em ambientes reais com novos dados.

Palavras-chave: Named Entity Recognition (NER); BERT-like; Large Language Models (LLMs); Particionamento de dados (splits).